

Atividade 3 - Redes Neurais Artificiais e Sistemas Neuro-Fuzzy

1st Guilherme Alvarenga de Azevedo
Departamento de Computação
CEFET-MG
Divinópolis, Brasil
guilherme@aluno.cefetmg.br

2nd Maria Eduarda Teixeira Souza
Departamento de Computação
CEFET-MG
Divinópolis, Brasil
maria@aluno.cefetmg.br

Resumo—A aplicação de algoritmos de Inteligência Computacional em tarefas de regressão exige um balanço cuidadoso entre a precisão preditiva e a interpretabilidade do modelo. Este artigo apresenta um estudo comparativo rigoroso entre arquiteturas de Redes Neurais Artificiais — especificamente o *Perceptron* de Múltiplas Camadas (MLP) [2] e as Redes de Função de Base Radial (RBF) [3] — e Sistemas Neuro-Fuzzy — representados pelo ANFIS [4] e pela Rede Neural Fuzzy baseada em agrupamento (FNN-FCM) [5]. Os modelos foram avaliados em quatro bases de dados reais de variadas dimensões e complexidades. Para garantir a validade estatística e atenuar vieses de inicialização estocástica, a metodologia adotou a otimização automatizada de hiperparâmetros via validação cruzada (*5-fold*) e a consolidação das métricas a partir de 21 execuções independentes para cada cenário. Os resultados evidenciam que o MLP possui maior escalabilidade e robustez no mapeamento de dados de alta dimensionalidade. Em contrapartida, o ANFIS demonstrou precisão superior e estabilidade determinística em espaços de características estruturados, embora seu custo computacional seja severamente penalizado pela maldição da dimensionalidade frente a múltiplos atributos. O estudo conclui delineando os limites práticos e os *trade-offs* entre abordagens *black-box* e baseadas em regras em previsões contínuas.

Index Terms—Redes Neurais Artificiais, Sistemas Neuro-Fuzzy, Regressão, ANFIS, Perceptron de Múltiplas Camadas, Otimização de Hiperparâmetros.

I. INTRODUÇÃO

A crescente demanda por previsões precisas em cenários práticos tem impulsionado a aplicação de algoritmos de Inteligência Computacional em tarefas de regressão e reconhecimento de padrões. Nesse contexto, modelos baseados em Redes Neurais Artificiais (RNAs), como o *Perceptron* de Múltiplas Camadas (MLP) [2], [10] e as Redes de Função de Base Radial (RBF) [3], [10], são amplamente adotados devido à alta capacidade de aprendizado e mapeamento de relações não lineares complexas. Paralelamente, os Sistemas Neuro-Fuzzy, representados pela arquitetura ANFIS [4], [11] e pelas Redes Neurais Fuzzy (FNN) [5], [11], combinam mecanismos de aprendizado conexionistas com conceitos da lógica fuzzy, constituindo uma alternativa viável para a modelagem interpretável de problemas de previsão contínua.

A aplicação prática dessas abordagens exige rigor metodológico. Bases de dados reais frequentemente apresentam desafios como alta dimensionalidade, variação extrema de escalas e ruídos nas amostras. Tais fatores podem comprometer

o desempenho dos algoritmos de regressão e induzir ao sobreajuste (*overfitting*), tornando essencial um tratamento prévio adequado dos atributos. Adicionalmente, a obtenção de taxas de erro reduzidas em uma execução isolada não é suficiente para atestar a robustez e a estabilidade de um algoritmo, dada a natureza estocástica de sua inicialização paramétrica.

Diante desse cenário, este trabalho tem como objetivo conduzir uma análise comparativa sistemática entre diferentes configurações de Redes Neurais Artificiais (MLP e RBF) e Sistemas Neuro-Fuzzy (ANFIS e FNN-FCM) em tarefas de regressão. O foco do estudo reside no processo de pré-processamento de dados, na escolha sistemática de hiperparâmetros, na avaliação quantitativa do aprendizado sob múltiplas execuções independentes e na discussão crítica do desempenho obtido em quatro conjuntos de dados públicos distintos.

O restante deste trabalho está estruturado da seguinte forma: a Seção II descreve os quatro conjuntos de dados e o pipeline de pré-processamento aplicado. A Seção III apresenta a análise exploratória de dados preliminar. A Seção IV aborda a fundamentação teórica dos algoritmos avaliados, enquanto a Seção V detalha os hiperparâmetros investigados. A Seção VI apresenta a metodologia experimental adotada. A Seção VII relata os detalhes de implementação do ecossistema computacional e a Seção VIII define as métricas de avaliação. Por fim, as Seções IX, X e XI expõem, respectivamente, os resultados quantitativos, a comparação direta entre as arquiteturas e a discussão crítica do desempenho, seguidas pelas conclusões na Seção XII.

II. CONJUNTOS DE DADOS E PRÉ-PROCESSAMENTO

Para avaliar o desempenho e a robustez dos algoritmos de Inteligência Computacional, foram selecionados quatro conjuntos de dados públicos disponíveis na plataforma Kaggle. Todos os conjuntos correspondem a problemas de regressão, nos quais o objetivo consiste em estimar uma variável de saída contínua a partir de um conjunto de atributos de entrada.

A seguir, são apresentadas as principais características de cada base de dados, incluindo o problema abordado, informações sobre a variável alvo e a dimensão original dos conjuntos:

- *Superstore (Profit)*: Base destinada à previsão do lucro (*Profit*) obtido em vendas de uma loja de varejo. A variável alvo apresenta valores entre -6.599,98 e 8.399,98, com

média de 28,77 e desvio-padrão de 234,83. O conjunto original contém 9.994 amostras e 21 atributos.

- *Flight Price*: Problema voltado à previsão do preço de passagens aéreas a partir de características do voo, como companhia aérea, horários e número de escalas. Os preços variam entre 1.105,00 e 123.071,00, com média de 20.976,45. Trata-se da maior base utilizada neste estudo, composta originalmente por 300.153 registros e 12 atributos.
- *Used Car Price*: Conjunto destinado à estimativa do preço de veículos usados. A variável alvo varia entre 2.000,00 e 2.954.083,00, apresentando média de 44.140,62. A base original possui 4.009 amostras e 12 atributos.
- *Obesity (Weight)*: Base utilizada para prever o peso (*Weight*) de indivíduos a partir de informações relacionadas a hábitos alimentares, condições físicas e histórico familiar. Os valores observados variam entre 39,00 e 173,00, com média de 86,86. O conjunto original é composto por 2.111 amostras e 17 atributos.

A. Pipeline de Pré-processamento

Para preparar os conjuntos de dados para as etapas de treinamento e avaliação, foi aplicado um pipeline de pré-processamento composto por procedimentos de limpeza, transformação e padronização dos atributos. As etapas foram executadas na seguinte ordem:

- 1) *Limpeza Inicial e Remoção de Duplicatas*: Atributos irrelevantes para a regressão (como IDs, nomes de clientes e datas específicas) foram descartados. Em seguida, instâncias duplicadas foram removidas. Foram eliminadas 50 amostras (0,5%) da *Superstore*, 2.213 amostras (0,7%) de *Flight Price* e 24 amostras (1,1%) de *Obesity*.
- 2) *Engenharia de Atributos (Feature Engineering)*: Esta etapa foi particularmente relevante para a base *Used Car Price*. Valores textuais complexos, como potência do motor e cilindrada, foram convertidos em atributos numéricos (*engine_hp* e *engine_liters*). Além disso, o atributo *model_year* foi transformado na idade do veículo, enquanto a alta cardinalidade das cores foi reduzida por meio de um processo de agrupamento em categorias simplificadas.
- 3) *Tratamento de Valores Ausentes (Missing Values)*: Apenas a base *Used Car Price* apresentou dados faltantes. Adotou-se a seguinte heurística: atributos com mais de 50% de ausência seriam descartados; para perdas entre 5% e 50%, aplicou-se a imputação pela mediana (para dados numéricos) ou moda (para categóricos), como ocorreu com o atributo *engine_hp*; para perdas inferiores a 5%, as respectivas linhas foram removidas. Ao final, 221 instâncias foram excluídas.
- 4) *Codificação de Variáveis Categóricas*: Atributos categóricos nominais com baixa cardinalidade (≤ 100 valores únicos) foram transformados utilizando *One-Hot Encoding*, mitigando o viés de ordem. Para atributos de

alta cardinalidade, como as cidades na base *Superstore*, aplicou-se o *Label Encoding*.

- 5) *Normalização dos Dados*: Como as RNAs e as funções de pertinência dos modelos Neuro-Fuzzy são sensíveis à escala dos dados, todos os atributos numéricos (incluindo a variável de saída) foram escalonados para o intervalo $[0, 1]$ através do método *Min-Max Scaler*:

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (1)$$

Após a conclusão do pré-processamento, as bases apresentaram as seguintes dimensões finais (amostras $\times$ atributos): *Superstore* com 9.944×78 , *Flight Price* com 297.940×30 , *Used Car Price* com 3.788×90 e *Obesity* com 2.087×22 . O aumento no número de atributos em algumas bases decorre principalmente da aplicação do *One-Hot Encoding* às variáveis categóricas.

III. ANÁLISE EXPLORATÓRIA DE DADOS

A análise exploratória de dados (EDA) foi realizada com o objetivo de caracterizar os conjuntos de dados utilizados neste estudo, compreender o comportamento das variáveis alvo e identificar possíveis relações entre os atributos e as saídas desejadas. Para cada base foram calculadas estatísticas descritivas, analisadas as distribuições das variáveis alvo e avaliadas as correlações lineares entre os atributos numéricos por meio do coeficiente de Pearson.

A. Superstore (Profit)

O conjunto *Superstore* possui 9.994 registros e 21 atributos. A variável alvo *Profit* apresentou média de 28,66, mediana de 8,67 e desvio-padrão de 234,26, indicando elevada dispersão dos resultados financeiros. Os valores observados variam entre -6.599,98 e 8.399,98.

A distribuição da variável alvo, apresentada na Figura 1, mostra forte concentração de observações próximas a lucros reduzidos e a presença de valores extremos tanto positivos quanto negativos. Esse comportamento sugere um problema de regressão com elevada variabilidade da saída.




Figura 1. Distribuição da variável alvo *Profit* no conjunto *Superstore*.

A Figura 2 apresenta o mapa de correlação entre os atributos numéricos. Observa-se que *Sales* possui a maior correlação positiva com o lucro ($r = 0,4791$), enquanto *Discount* apresenta

correlação negativa ($r = -0,2195$). Embora relevantes, essas correlações indicam que a relação entre os atributos e o lucro não é predominantemente linear.




Figura 2. Mapa de correlação dos atributos numéricos do conjunto Superstore.

B. Flight Price

A base *Flight Price* é a maior utilizada neste trabalho, contendo 300.153 registros e 12 atributos. A variável alvo *price* apresenta média de 20.889,66, mediana de 7.425,00 e desvio-padrão de 22.697,77, evidenciando uma distribuição bastante assimétrica.

Conforme mostrado na Figura 3, a maior parte das passagens concentra-se em faixas de menor preço, enquanto uma parcela reduzida das amostras apresenta valores significativamente superiores, formando uma longa cauda à direita.




Figura 3. Distribuição da variável alvo *price* no conjunto Flight Price.

O mapa de correlação da Figura 4 mostra que o atributo *duration* apresenta a associação positiva mais relevante com o preço ($r = 0,2042$), enquanto *days_left* apresenta correlação negativa ($r = -0,0919$). Esses resultados sugerem que voos mais longos tendem a ser mais caros e que compras realizadas

mais próximas da data da viagem tendem a apresentar preços mais elevados.




Figura 4. Mapa de correlação dos atributos numéricos do conjunto Flight Price.

C. Used Car Price

O conjunto *Used Car Price* possui 4.009 registros e 12 atributos. Durante a EDA observou-se que diversos atributos relevantes, incluindo a própria variável alvo, estavam armazenados como texto contendo símbolos monetários e informações agregadas. Essa característica impossibilitava análises estatísticas completas antes da etapa de pré-processamento.

Mesmo nessa condição, a distribuição apresentada na Figura 5 permitiu identificar uma ampla dispersão dos preços dos veículos, variando entre 2.000,00 e 2.954.083,00, com média de 44.553,19. A elevada amplitude dos valores reforçou a necessidade das etapas de engenharia de atributos e normalização descritas na Seção II.




Figura 5. Distribuição da variável alvo *price* no conjunto Used Car Price.

Entre os atributos originalmente numéricos, apenas *model_year* apresentou correlação relevante com o preço ($r =$

0,1995), indicando uma tendência de valorização de veículos mais recentes.

D. Obesity (Weight)

O conjunto *Obesity* contém 2.111 registros e 17 atributos relacionados a hábitos alimentares, características físicas e estilo de vida. A variável alvo *Weight* apresenta média de 86,59, mediana de 83,00 e desvio-padrão de 26,19, variando entre 39,00 e 173,00.

A Figura 6 mostra uma distribuição relativamente ampla da variável peso, refletindo a diversidade dos indivíduos presentes na base e a coexistência de diferentes perfis corporais.




Figura 6. Distribuição da variável alvo *Weight* no conjunto *Obesity*.

A análise das correlações lineares, apresentada na Figura 7, indica que a altura (*Height*) possui a associação mais forte com o peso ($r = 0,4631$), seguida pelos atributos *FCVC* ($r = 0,2161$) e *Age* ($r = 0,2026$). Apesar dessas relações, os coeficientes observados sugerem que parte significativa da variabilidade do peso depende de interações mais complexas entre os atributos.




Figura 7. Mapa de correlação dos atributos numéricos do conjunto *Obesity*.

A Tabela I resume os atributos que apresentaram as maiores correlações lineares com as respectivas variáveis alvo. De maneira geral, os coeficientes observados são moderados, indicando que nenhum dos problemas pode ser adequadamente modelado apenas por relações lineares simples. Essa característica justifica a utilização de modelos não lineares, como Redes Neurais Artificiais e Sistemas Neuro-Fuzzy, investigados nas próximas seções.

Tabela I
PRINCIPAIS CORRELAÇÕES LINEARES COM A VARIÁVEL ALVO (r)

Conjunto de Dados	Variável Alvo	Atributo Numérico	Correlação (r)
Superstore	Profit	Sales	+0,4791
Superstore	Profit	Discount	-0,2195
Flight Price	price	duration	+0,2042
Flight Price	price	days_left	-0,0919
Obesity	Weight	Height	+0,4631
Obesity	Weight	FCVC	+0,2161
Obesity	Weight	Age	+0,2026

IV. ALGORITMOS AVALIADOS

Este trabalho compara duas abordagens amplamente empregadas em Inteligência Computacional para tarefas de regressão: as Redes Neurais Artificiais (RNAs) e os Sistemas Neuro-Fuzzy. Enquanto as RNAs realizam a modelagem por meio de estruturas conexionistas capazes de aprender relações complexas entre atributos e saídas, os Sistemas Neuro-Fuzzy incorporam conceitos da lógica fuzzy ao processo de aprendizado, permitindo representar o conhecimento por meio de regras e funções de pertinência. Foram avaliados quatro modelos: MLP, RBF, ANFIS e FNN-FCM.

A. Perceptron de Múltiplas Camadas (MLP)

O Perceptron de Múltiplas Camadas (*Multilayer Perceptron* – MLP) é uma rede neural do tipo *feedforward* treinada por meio do algoritmo de retropropagação do erro. Sua arquitetura é composta por uma camada de entrada, uma ou mais camadas ocultas e uma camada de saída.

As camadas ocultas utilizam funções de ativação não lineares, permitindo ao modelo aprender relações complexas entre os atributos de entrada e a variável alvo. Devido à sua capacidade de aproximação universal, o MLP é frequentemente utilizado como referência em problemas de regressão e previsão. Neste trabalho, diferentes configurações arquiteturais e parâmetros de treinamento foram avaliados durante o processo de otimização.

B. Rede de Função de Base Radial (RBF)

A Rede de Função de Base Radial (*Radial Basis Function* – RBF) é uma arquitetura neural composta por uma camada de entrada, uma camada oculta formada por funções radiais e uma camada de saída linear. Diferentemente do MLP, a RBF realiza aproximações locais, utilizando funções centradas em regiões específicas do espaço de características.

Cada neurônio da camada oculta responde de forma mais intensa a amostras próximas ao seu centro de influência,

permitindo a construção da aproximação global a partir da combinação de diversas respostas locais. Essa característica torna a RBF uma alternativa interessante para modelar problemas com padrões localizados e não lineares.

C. Sistema de Inferência Neuro-Fuzzy Adaptativo (ANFIS)

O ANFIS (*Adaptive Neuro-Fuzzy Inference System*) combina mecanismos de aprendizado inspirados em redes neurais com um Sistema de Inferência Fuzzy baseado no modelo de Takagi-Sugeno. Sua estrutura pode ser representada como uma rede adaptativa responsável por ajustar automaticamente os parâmetros das funções de pertinência e das regras fuzzy.

O funcionamento do modelo envolve a fuzificação das entradas, a avaliação das regras, a normalização dos graus de ativação e o cálculo da saída por meio de funções consequentes. Dessa forma, o ANFIS busca unir a capacidade de aprendizado dos modelos conexionistas à representação fuzzy do conhecimento.

D. Rede Neural Fuzzy baseada em Fuzzy C-Means (FNN-FCM)

A Rede Neural Fuzzy baseada em agrupamento *Fuzzy C-Means* (FNN-FCM) utiliza técnicas de agrupamento difuso para construir automaticamente a base de regras do sistema. Em vez de gerar regras a partir de particionamentos em grade, o modelo identifica agrupamentos diretamente nos dados, utilizando cada grupo para representar uma região do espaço de características.

Essa estratégia reduz o crescimento do número de regras em problemas com maior dimensionalidade, tornando o modelo mais escalável do que abordagens neuro-fuzzy tradicionais. Além disso, a utilização do agrupamento FCM permite representar de forma natural a sobreposição entre diferentes regiões dos dados, característica inerente à lógica fuzzy.

V. PARÂMETROS INVESTIGADOS

Para assegurar que cada algoritmo atingisse seu máximo potencial de generalização e evitar a arbitrariedade na escolha de configurações, realizou-se uma busca sistemática de hiperparâmetros. A definição do espaço de busca levou em consideração as particularidades matemáticas e estruturais de cada modelo. A seguir, detalham-se os hiperparâmetros investigados para cada arquitetura durante a fase de otimização automatizada:

A. Parâmetros do MLP

Para a Rede Neural Perceptron de Múltiplas Camadas, a otimização focou na topologia e na dinâmica de convergência do gradiente:

- *Topologia Oculta (hidden_layer_sizes)*: Variação na profundidade (número de camadas) e na largura (número de neurônios por camada) da rede.
- *Função de Ativação (activation)*: Investigação de funções não lineares, como a Unidade Linear Retificada (ReLU).
- *Otimizador (solver)*: Algoritmo responsável pela atualização dos pesos, como Adam, SGD ou L-BFGS.

- *Taxa de Aprendizado (learning_rate_init)*: O tamanho do passo inicial na direção contrária ao gradiente de erro.
- *Regularização L2 (alpha)*: Fator de penalização dos pesos sinápticos para prevenir o sobreajuste (*overfitting*).

B. Parâmetros da RBF

Na Rede de Função de Base Radial, a busca concentrou-se na distribuição espacial das funções locais:

- *Número de Centros (n_centers)*: Quantidade de funções radiais alocadas na camada oculta para mapear o espaço de características.
- *Espalhamento (sigma)*: O raio de influência (*width*) da função gaussiana.
- *Modo do Sigma (sigma_mode)*: Definição de espalhamentos homogêneos (mesmo valor para todos) ou heterogêneos (um sigma específico por centro).
- *Regularização (alpha)*: Termo de penalização aplicado ao ajuste por mínimos quadrados da camada de saída linear.

C. Parâmetros do ANFIS

Para o Sistema Neuro-Fuzzy ANFIS, os hiperparâmetros definiram a granularidade das regras e o ajuste das funções de pertinência:

- *Número de Funções de Pertinência (n_mfs)*: Quantidade de conjuntos fuzzy atribuídos a cada variável de entrada.
- *Tipo de Função de Pertinência (mf_type)*: A geometria dos conjuntos fuzzy (triangular, gaussiana ou em formato de sino/bell).
- *Taxa de Aprendizado (learning_rate)*: Regulagem do ajuste não linear das premissas pelo gradiente descendente.
- *Épocas (n_epochs)*: Número de iterações completas de treinamento (variando, por exemplo, de 50 a 300).
- *Regularização Consequente (lambda_reg)*: Penalização aplicada na determinação dos coeficientes lineares das regras de Takagi-Sugeno.

D. Parâmetros do FNN-FCM

Na variante Neuro-Fuzzy baseada em agrupamento, a otimização priorizou os parâmetros que controlam a formação dos protótipos locais:

- *Número de Clusters (n_clusters)*: Quantidade de agrupamentos difusos gerados pelo algoritmo *Fuzzy C-Means*, que define diretamente a quantidade de regras do sistema.
- *Grau de Fuzificação (fuzziness)*: O expoente de peso do FCM, que controla o nível de sobreposição e suavidade nas fronteiras dos grupos.
- *Geometria e Limiares (mf_type e similarity_threshold)*: O formato da função de pertinência associada a cada cluster e o limiar matemático para fusão ou descarte de regras redundantes.
- *Ajuste Fino (learning_rate e n_epochs)*: Dinâmica de atualização dos pesos da camada consequente durante o refinamento supervisionado.

VI. METODOLOGIA EXPERIMENTAL

Para garantir uma avaliação justa, reprodutível e estatisticamente sólida dos modelos conexionistas e neuro-fuzzy, estruturou-se um protocolo experimental rigoroso. O fluxo de trabalho engloba desde a partição inicial dos dados até uma arquitetura de execução distribuída projetada para contornar o elevado custo computacional das simulações.

A. Divisão dos Dados e Validação Cruzada

O ecossistema de dados foi submetido a uma partição estrita em duas macrofases estruturadas em uma proporção inicial de 80/20:

- 1) *Conjunto de Teste Final (20%)*: Uma fração isolada de cada base de dados reservada exclusivamente para o teste cego. Esse subconjunto permaneceu intocado durante todo o processo de ajuste e otimização, sendo acionado apenas na etapa derradeira para avaliar a capacidade de generalização dos modelos de forma isenta.
- 2) *Conjunto de Ajuste Paramétrico (80%)*: Destinado ao treinamento e busca de hiperparâmetros. Para mitigar problemas de sobreajuste (*overfitting*) e conferir robustez à seleção de configurações, aplicou-se a validação cruzada *k-fold* com $k = 5$ (sendo flexibilizado para $k = 3$ sob o modelo ANFIS na base de alta densidade *Flight Price*).

Vale destacar a dinâmica matemática decorrente desse arranjo: sob a ótica operacional do método *5-fold cross-validation*, os 80% destinados ao ajuste são fracionados internamente a cada rodada. Assim, 64% da base original atuam no ajuste efetivo de pesos, enquanto 16% funcionam como validação local. Esse fluxo rotacional atende de forma dinâmica e rigorosa às recomendações de particionamento do projeto.

B. Busca de Hiperparâmetros e Amostragem Estatística

A otimização das arquiteturas foi conduzida de forma automatizada por meio da biblioteca *Optuna*, configurada para executar 15 tentativas (*trials*) de busca por modelo e base de dados. O objetivo do otimizador foi minimizar a Raiz do Erro Quadrático Médio (*RMSE*) obtida na validação cruzada descrita anteriormente.

Definida a melhor configuração teórica, os modelos foram instanciados e treinados com a totalidade da base de ajuste (80%), sendo em seguida avaliados no conjunto de teste final (20%). Considerando a presença de componentes estocásticos intrínsecos à inicialização dos algoritmos — como as matrizes de pesos aleatórias nas RNAs e o posicionamento inicial de centroides no agrupamento *Fuzzy C-Means* —, análises baseadas em uma única execução são metodologicamente insuficientes. Desse modo, o treinamento e a predição definitivos foram repetidos por 21 execuções independentes sob as mesmas sementes e divisões exatas, garantindo a paridade da amostragem e permitindo inferir médias e desvios-padrão estáveis para todas as métricas.

Para atestar a validade das comparações de desempenho e verificar se a superioridade de um algoritmo sobre os demais

é estatisticamente significativa, adotou-se a aplicação de testes estatísticos não paramétricos, como o Teste de Wilcoxon, sobre as amostras das 21 execuções, assumindo um nível de significância de $\alpha = 0,05$. Essa abordagem garante que as conclusões inferidas não sejam fruto de variações estocásticas aleatórias.

C. Arquitetura de Execução Distribuída e Consolidação

O pipeline experimental projetado impõe um desafio computacional crítico. A combinação de algoritmos complexos (especialmente o ANFIS, sujeito à explosão combinatória de regras baseada em partições em grade) com bases de dados massivas (como a *Flight Price*, contendo quase 300 mil instâncias) resulta em tempos de execução proibitivos para uma única máquina de processamento sequencial.

Para contornar essa limitação e viabilizar os experimentos em tempo hábil, foi desenvolvida uma estratégia de ***particionamento de carga de trabalho e execução distribuída***. O menu principal do sistema unificado foi projetado para segmentar logicamente as tarefas mais onerosas em quatro perfis independentes de execução (computadores), distribuindo a carga da seguinte forma:

- *Computador 1*: Alocado especificamente para processar o cenário mais crítico do pipeline: a base de dados *Flight Price* operando exclusivamente sob o algoritmo *ANFIS*.
- *Computador 2*: Responsável pelo processamento da base *Flight Price* utilizando apenas a arquitetura *FNN-FCM*.
- *Computador 3*: Encarregado de executar as Redes Neurais Artificiais puras (*MLP* e *RBF*) sobre a base volumosa de *Flight Price*.
- *Computador 4*: Configurado para assumir a execução completa (todos os quatro modelos: *MLP*, *RBF*, *ANFIS* e *FNN-FCM*) sobre os três conjuntos de dados restantes (*Superstore*, *Used Car Price* e *Obesity*), que possuem menor dimensionalidade e volumetria de amostras.

Cada nó da rede distribuída gerou seus respectivos arquivos locais de registro em formato estruturado (*all_results.csv* e *summary.csv*), isolados por pastas de identificação de cenário. Após o término do processamento paralelo nas quatro frentes, implementou-se um módulo automatizado de integração (*consolidate.py*). Este script varre a árvore de diretórios dos resultados parciais, extrai as matrizes de métricas agregadas das 21 execuções e consolida os dados em uma única base unificada de dados (*global_summary.csv*). Esse fluxo garante a integridade e a homogeneidade analítica necessárias para a construção das tabelas e discussões comparativas apresentadas a seguir.

VII. DESCRIÇÃO DA IMPLEMENTAÇÃO

Todo o ecossistema do projeto foi desenvolvido utilizando a linguagem de programação Python 3. Para a manipulação, limpeza e codificação das bases de dados em larga escala, fez-se uso intensivo das bibliotecas *Pandas* e *Scikit-learn*. A busca sistemática e automatizada pelos hiperparâmetros ótimos de cada arquitetura foi guiada pela biblioteca *Optuna*, garantindo

uma exploração eficiente do espaço de configurações. As operações matemáticas e matriciais que sustentam os cálculos das Redes Neurais e dos Sistemas Neuro-Fuzzy foram viabilizadas pelo módulo *NumPy*.

Para fins de total transparência e reprodutibilidade metodológica, o código-fonte completo — englobando a rotina de pré-processamento, a configuração da execução distribuída e os algoritmos de predição — está devidamente organizado e disponível para consulta pública em [1].

VIII. MÉTRICAS DE AVALIAÇÃO

Para aferir a qualidade do mapeamento contínuo e avaliar quantitativamente os erros residuais de previsão[cite: 1636], foram adotadas quatro métricas de desempenho. Considerando N como o número total de amostras do conjunto de teste, y_i como o valor real do alvo, $\hat{y}_i$ como o valor estimado pelo modelo e $\bar{y}$ como a média das saídas reais, as métricas são definidas por:

- 1) *Erro Quadrático Médio (MSE)*: Quantifica a média dos erros elevados ao quadrado, destacando desvios maiores. É dado por:

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (2)$$

- 2) *Raiz do Erro Quadrático Médio (RMSE)*: Avalia a magnitude do erro penalizando de forma mais severa os desvios discrepantes (*outliers*)[cite: 1636]. É dada por:

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \quad (3)$$

- 3) *Erro Absoluto Médio (MAE)*: Calcula a média das diferenças absolutas entre as predições e os valores reais[cite: 1637], fornecendo uma noção direta do erro na mesma escala original dos dados:

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (4)$$

- 4) *Coefficiente de Determinação (R^2)*: Métrica de correlação que indica a proporção da variância dos dados que o modelo é capaz de explicar[cite: 1637]. O valor máximo perfeito é 1. Modelos que apenas preveem a média dos dados resultam em $R^2 = 0$.

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2} \quad (5)$$

- 5) *Erro Percentual Absoluto Médio (MAPE)*: Dimensiona o erro de forma relativa, expressando o quão longe a predição está do valor verdadeiro em termos de porcentagem.

$$MAPE = \frac{100\%}{N} \sum_{i=1}^N \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (6)$$

As métricas calculadas na fase de avaliação final são organizadas e dispostas em tabelas comparativas para cada um dos quatro cenários na Seção IX.

IX. RESULTADOS QUANTITATIVOS

Esta seção apresenta os resultados brutos obtidos após o treinamento e avaliação das quatro arquiteturas propostas. Para garantir a confiabilidade estatística e mitigar o impacto de inicializações estocásticas, os valores reportados nas tabelas a seguir correspondem à média e ao desvio-padrão das métricas extraídas das 21 execuções independentes de cada modelo sobre o conjunto de teste isolado (20%).

A. Resultados: Superstore (Profit)

O conjunto *Superstore* demonstrou ser altamente favorável à abordagem Neuro-Fuzzy clássica. Conforme detalhado na Tabela II, o modelo ANFIS obteve o menor erro preditivo absoluto e quadrático, além de atingir o maior coeficiente de determinação ($R^2 \approx 0,9384$). Destaca-se também a notável estabilidade do ANFIS, que apresentou desvio-padrão virtualmente nulo ao longo das execuções, um comportamento evidenciado no gráfico de caixas (*boxplot*) gerado pela ferramenta de análise. Em contrapartida, as arquiteturas RBF e FNN-FCM não conseguiram mapear adequadamente a variância do lucro, resultando em métricas de erro severamente degradadas.

Tabela II
DESEMPENHO PREDITIVO - DATASET SUPERSTORE (21 EXECUÇÕES)

Modelo	RMSE	MAE	R^2	MAPE
MLP	84,70 ± 20,39	27,97 ± 8,61	0,9117 ± 0,04	226,32 ± 191,31
RBF	242,33 ± 8,63	56,52 ± 0,66	0,3140 ± 0,05	555,46 ± 25,59
ANFIS	72,69 ± 0,00	25,38 ± 0,00	0,9384 ± 0,00	162,92 ± 0,00
FNN-FCM	227,25 ± 0,95	62,69 ± 0,23	0,3974 ± 0,00	773,83 ± 4,68




Figura 8. Dispersão do erro (RMSE) nas 21 execuções para a base Superstore.

B. Resultados: Flight Price

A base de dados de passagens aéreas, sendo a mais volumosa do estudo (> 290 mil registros), exigiu grande capacidade de generalização dos algoritmos. A Tabela III revela que a Rede Neural Perceptron de Múltiplas Camadas (MLP) obteve o desempenho superior absoluto ($R^2 \approx 0,9651$). O ANFIS manteve uma taxa preditiva competitiva e altamente estável (*RMSE* com desvio de apenas 4,06).

Tabela III
DESEMPENHO PREDITIVO - DATASET FLIGHT PRICE (21 EXECUÇÕES)

Modelo	RMSE	MAE	R^2	MAPE
MLP	4238,25 ± 213,91	2482,72 ± 139,73	0,9651 ± 0,00	24,11 ± 1,11
RBF	8953,51 ± 201,29	5852,17 ± 151,78	0,8443 ± 0,01	54,57 ± 1,32
ANFIS	6043,10 ± 4,06	3968,75 ± 9,37	0,9289 ± 0,00	35,25 ± 0,31
FNN-FCM	7808,97 ± 335,60	4950,41 ± 195,45	0,8816 ± 0,01	46,38 ± 1,72

C. Resultados: Used Car Price

O problema de precificação de carros usados apresentou a maior complexidade de mapeamento, refletindo na queda substancial do R^2 geral, como exposto na Tabela IV. O alto número de atributos derivados (*One-Hot Encoding*) e a forte não linearidade do mercado automobilístico penalizaram drasticamente a RBF e o FNN-FCM, que não conseguiram explicar sequer 5% da variância dos dados. O modelo MLP demonstrou a melhor capacidade de isolamento de ruídos, registrando o menor erro percentual (*MAPE*) e explicando cerca de 72% da variância dos preços.

Tabela IV
DESEMPENHO PREDITIVO - DATASET USED CAR PRICE (21 EXECUÇÕES)

Modelo	RMSE	MAE	R^2	MAPE
MLP	40662,62 ± 2005,15	19553,79 ± 1210,50	0,7202 ± 0,03	41,38 ± 1,80
RBF	76602,82 ± 10,96	34187,35 ± 11,23	0,0069 ± 0,00	104,23 ± 0,02
ANFIS	48805,52 ± 0,00	20562,99 ± 0,00	0,5968 ± 0,00	59,55 ± 0,00
FNN-FCM	75317,06 ± 1290,72	32906,50 ± 901,89	0,0399 ± 0,03	98,95 ± 3,23




Figura 9. Distribuição do Coeficiente de Determinação (R^2) na base de Carros Usados.

D. Resultados: Obesity (Weight)

A estimativa de peso corporal revelou-se um problema onde abordagens puramente conexionistas prevaleceram. De acordo com a Tabela V, tanto o MLP quanto a RBF atingiram taxas de predição satisfatórias ($R^2 > 0,83$). Curiosamente, as abordagens fuzzy não conseguiram construir espaços de inferência competentes, com destaque negativo para o agrupamento do FNN-FCM, que resultou em um R^2 levemente negativo, indicando que seu conjunto de regras gerou estimativas piores do que a simples média global da base.

Tabela V
DESEMPENHO PREDITIVO - DATASET OBESITY (21 EXECUÇÕES)

Modelo	RMSE	MAE	R^2	MAPE
MLP	9,80 ± 0,20	6,48 ± 0,16	0,8637 ± 0,01	8,98 ± 0,20
RBF	10,68 ± 0,09	8,08 ± 0,12	0,8381 ± 0,00	11,19 ± 0,15
ANFIS	18,06 ± 0,00	14,50 ± 0,00	0,5369 ± 0,00	21,38 ± 0,00
FNN-FCM	26,25 ± 0,00	21,67 ± 0,00	-0,0003 ± 0,00	29,33 ± 0,00

X. COMPARAÇÃO ENTRE OS ALGORITMOS

A avaliação das métricas de desempenho ao longo dos quatro conjuntos de dados indica que a eficácia de cada algoritmo depende diretamente das características de dimensionalidade e distribuição de cada problema. A seguir, discutem-se as principais diferenças observadas entre as abordagens quanto à capacidade preditiva, distribuição dos erros e custo computacional.

A. Capacidade Preditiva e Versatilidade

A arquitetura *Perceptron* de Múltiplas Camadas (MLP) demonstrou maior versatilidade preditiva no escopo deste trabalho, obtendo os menores índices de erro em três dos quatro cenários analisados (*Flight Price*, *Used Car Price* e *Obesity*). Esse comportamento sugere uma maior capacidade do modelo supervisionado em extrair representações não lineares consistentes em bases de dados com diferentes volumetrias e alta dimensionalidade de atributos.

Por sua vez, o Sistema Neuro-Fuzzy ANFIS apresentou o melhor desempenho no conjunto *Superstore*, caracterizado por uma relação estruturada entre variáveis que se beneficia do particionamento espacial em grade (*grid partitioning*). Na base *Flight Price*, o ANFIS também manteve um desempenho comparável ao do MLP. A Figura 10 ilustra essa proximidade nas métricas de Coeficiente de Determinação (R^2).




Figura 10. Comparativo do Coeficiente de Determinação (R^2) na base Flight Price.

Em contraste, os modelos de aproximação estritamente local (RBF e FNN-FCM) apresentaram limitações em bases de maior complexidade. A estratégia de mapeamento radial e o agrupamento difuso resultaram em métricas de ajuste substancialmente inferiores, especialmente no conjunto *Used*

Car Price, onde os modelos não conseguiram convergir para predições representativas da variância dos preços.

B. Análise de Dispersão dos Erros

Além das métricas globais, a análise gráfica da dispersão fornece indícios sobre o comportamento dos modelos diante de diferentes faixas de valores. As Figuras 11 e 12 apresentam a relação entre os valores reais e as predições geradas pelos modelos MLP e ANFIS na base *Flight Price*.




Figura 11. Dispersão Real vs. Predito para o modelo MLP (*Flight Price*). Observa-se a concentração geométrica próxima à diagonal ideal de identidade.




Figura 12. Dispersão Real vs. Predito para o modelo ANFIS (*Flight Price*). Nota-se uma tendência de dispersão e subestimação na região de valores extremos (cauda direita).

A visualização indica que o modelo MLP apresenta uma distribuição de erros mais simétrica em relação à reta identidade, mantendo consistência inclusive nas faixas de valores mais altos. O modelo ANFIS, embora apresente alta precisão na maior parte da distribuição, demonstra maior variância e uma tendência geométrica de subestimação frente a instâncias extremas (*outliers*). Essa característica justifica a diferença observada nas tabelas entre o *RMSE* e o *MAE*, visto que desvios de alta magnitude penalizam o erro quadrático com maior severidade.

C. Complexidade Computacional e Escalabilidade

As arquiteturas avaliadas apresentaram diferenças expressivas em relação ao custo computacional exigido para o treinamento. O modelo MLP demandou tempo de processamento

intensivo durante a otimização dos gradientes estocásticos, porém configurou-se como um modelo leve para a fase de inferência.

A principal limitação técnica observada no sistema ANFIS reside em sua escalabilidade frente a bases de dados com alta dimensionalidade. O método tradicional de particionamento em grade gera um crescimento exponencial do número de regras baseadas nas funções de pertinência, fenômeno que eleva drasticamente o consumo de memória RAM e o esforço de processamento matricial. Essa característica estrutural exigiu que o treinamento do modelo ANFIS para a base volumosa *Flight Price* ocorresse em um ambiente computacional dedicado e isolado, evidenciando as restrições da abordagem Neuro-Fuzzy clássica no tratamento de volumes massivos de dados multidimensionais.

XI. DISCUSSÃO CRÍTICA

Os resultados experimentais evidenciam que a escolha da arquitetura ideal para problemas de regressão exige a ponderação de múltiplos fatores, transcendendo a simples busca pela minimização do erro. A seguir, discute-se o balanço entre transparência e desempenho, os desafios computacionais inerentes a cada abordagem e as limitações da metodologia adotada.

A. Interpretabilidade versus Desempenho Preditivo

Um dos principais debates na Inteligência Computacional refere-se ao *trade-off* entre modelos de "caixa-preta" (*black-boxes*) e sistemas baseados em conhecimento transparente. As Redes Neurais Artificiais, representadas pelo MLP, confirmaram sua superioridade preditiva global e facilidade de ajuste dinâmico em bases com relações complexas e ruídos espaciais, como o caso de *Used Car Price* e *Obesity*. Contudo, o conhecimento adquirido pelo MLP fica distribuído em matrizes de pesos sinápticos, impossibilitando a extração de justificativas lógicas para uma dada predição.

Em contrapartida, os Sistemas Neuro-Fuzzy (ANFIS e FNN-FCM) oferecem um nível de interpretabilidade ímpar. O ajuste das funções de pertinência permite mapear a lógica de decisão em regras do tipo SE-ENTÃO, aproximando o modelo do raciocínio humano. Observou-se, no entanto, que a preservação dessa interpretabilidade cobrou um preço no desempenho: enquanto o ANFIS conseguiu aliar alta precisão e transparência na base *Superstore*, a variante FNN-FCM sacrificou excessivamente a aderência preditiva ao tentar simplificar o espaço de regras por meio de agrupamentos, apresentando subajuste (*underfitting*) na maioria dos cenários avaliados.

B. Dimensionalidade, Complexidade e Sensibilidade

A dimensionalidade dos dados (número de atributos) provou ser o fator mais limitante para as abordagens Neuro-Fuzzy. O modelo ANFIS tradicional opera sob o particionamento em grade (*grid partitioning*), o que significa que o número de regras cresce exponencialmente em função do número de variáveis de entrada e das funções de pertinência alocadas ("maldição da dimensionalidade"). Em bases como *Flight*

Price e *Used Car Price*, que possuíam de 30 a 90 atributos após a codificação *One-Hot*, a explosão combinatória inviabilizou a alocação de um número elevado de conjuntos fuzzy, limitando o modelo a mapeamentos mais rasos e gerando um custo computacional extremo.

Já as Redes Neurais demonstraram maior escalabilidade estrutural. O MLP, parametrizado com algoritmos de otimização de gradiente em lotes (*Adam*), lidou naturalmente com a alta dimensionalidade sem sofrer expansão geométrica de sua arquitetura. No entanto, as análises de variância comprovaram que o MLP e a RBF são estatisticamente mais sensíveis à inicialização aleatória dos parâmetros. A dispersão observada nos *boxplots* das 21 execuções atesta que, mesmo utilizando hiperparâmetros ótimos definidos pelo *Optuna*, uma "má" inicialização de pesos pode degradar severamente uma rodada de predição neural, ao passo que os sistemas fuzzy (notadamente o ANFIS) apresentaram uma estabilidade determinística superior uma vez configuradas as premissas.

C. Limitações do Estudo e Trabalhos Futuros

A metodologia experimental adotada, embora robusta estatisticamente e validada por múltiplas execuções, apresenta limitações estruturais. A principal delas reside na ausência de técnicas avançadas de redução de dimensionalidade (como a Análise de Componentes Principais - PCA) durante o pré-processamento. A aplicação de PCA poderia condensar as dezenas de atributos gerados pela codificação das variáveis categóricas, aliviando o esforço matricial do ANFIS e potencialmente melhorando a separabilidade dos agrupamentos no FNN-FCM.

Além disso, o elevado custo computacional forçou a segmentação das execuções em quatro máquinas físicas, o que impossibilita a aferição padronizada de métricas de tempo de inferência e de treinamento cruzado sob o mesmo *hardware*. Para trabalhos futuros, sugere-se a implementação de abordagens de particionamento fuzzy baseadas em árvores (*tree-based partitioning*) ou algoritmos genéticos para a poda das bases de regras, buscando uma otimização que preserve a transparência do raciocínio sem sucumbir à complexidade de dados massivos.

XII. CONCLUSÃO

Este trabalho apresentou uma avaliação comparativa entre duas vertentes da Inteligência Computacional — as Redes Neurais Artificiais (MLP e RBF) e os Sistemas Neuro-Fuzzy (ANFIS e FNN-FCM) — aplicadas a quatro problemas distintos de regressão contínua. Em conformidade com as diretrizes metodológicas estabelecidas, o foco estendeu-se além da busca isolada pelo menor erro, priorizando a análise de sensibilidade paramétrica através do otimizador *Optuna*, a validação cruzada *5-fold* e a avaliação da estabilidade estatística fundamentada em 21 execuções independentes.

Os resultados empíricos permitiram mapear o compromisso entre a capacidade preditiva e a interpretabilidade dos modelos. A arquitetura MLP consolidou-se como a abordagem mais versátil no escopo dos testes, obtendo o desempenho

superior na maioria dos cenários devido à sua escalabilidade frente a atributos de alta dimensionalidade gerados pelo pré-processamento. Por outro lado, o modelo ANFIS demonstrou elevada eficácia em bases de dados com relações espaciais estruturadas, como o conjunto *Superstore*, destacando-se pela consistência e baixa variância entre as execuções, embora limitado pela expansão exponencial de sua base de regras diante de múltiplos atributos. Por fim, os modelos baseados em aproximações locais, RBF e FNN-FCM, evidenciaram restrições de convergência em distribuições de alta complexidade e ruído, como a base de precificação de veículos usados.

Como contribuição metodológica, o estudo validou a eficácia do uso de uma estratégia de processamento distribuído para viabilizar pipelines experimentais onerosos em tempo hábil, além de detalhar os limites práticos de escalabilidade e transparência de cada algoritmo. Como trabalhos futuros, sugere-se a integração de métodos de redução de dimensionalidade, como a Análise de Componentes Principais (PCA), e a investigação de técnicas de poda e seleção de regras fuzzy baseadas em algoritmos evolucionários, visando atenuar o custo computacional sem comprometer a interpretabilidade.

REFERÊNCIAS

- [1] G. A. Azevedo and M. E. T. Souza, "Atividade 03 - Redes Neurais e Sistemas Neuro-Fuzzy," 2026. [Online]. Disponível em: <https://github.com/alvarengazv/rna-neuro-fuzzy-ic>.
- [2] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, "Learning representations by back-propagating errors," *Nature*, vol. 323, no. 6088, pp. 533–536, 1986.
- [3] J. Moody and C. J. Darken, "Fast learning in networks of locally-tuned processing units," *Neural Computation*, vol. 1, no. 2, pp. 281–294, 1989.
- [4] J.-S. R. Jang, "ANFIS: adaptive-network-based fuzzy inference system," *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 23, no. 3, pp. 665–685, 1993.
- [5] C.-T. Lin and C. S. G. Lee, "Neural-network-based fuzzy logic control and decision system," *IEEE Transactions on Computers*, vol. 40, no. 12, pp. 1320–1336, 1991.
- [6] A. M. Silva, "Inteligência Computacional: Notas de Aula 05 — Fuzzy Introdução," Notas de Aula, 2026.
- [7] A. M. Silva, "Inteligência Computacional: Notas de Aula 06 — Fuzzy Conjuntos," Notas de Aula, 2026.
- [8] A. M. Silva, "Inteligência Computacional: Notas de Aula 08 — Fuzzy Inferência 01," Notas de Aula, 2026.
- [9] A. M. Silva, "Inteligência Computacional: Notas de Aula 10 — Agrupamento," Notas de Aula, 2026.
- [10] A. M. Silva, "Inteligência Computacional: Notas de Aula 11 — Redes Neurais Artificiais," Notas de Aula, 2026.
- [11] A. M. Silva, "Inteligência Computacional: Notas de Aula 12 — Redes Neuro-Fuzzy," Notas de Aula, 2026.