



## Atividade 3 - Redes Neurais Artificiais e Sistemas Neuro-Fuzzy

Guilherme Alvarenga de Azevedo  
Maria Eduarda Teixeira Souza


CEFET-MG

2026




- **Desafio estatístico:** Coexistência de problemas com baixa volumetria e bases densas de alta dimensionalidade linear.

- **Objetivo:** Identificar padrões de distribuição, correlações lineares entre atributos e detecção de *outliers* que impactam o treinamento.
- **Principais observações:**
  - Identificação de alta correlação em variáveis explicativas (colinearidade).
  - Disparidade entre escalas nas variáveis de entrada.
  - Distribuição das variáveis alvo com comportamento assimétrico (caudas longas).



# EDA: Distribuição do Alvo (Flight Price)



## Pipeline de Pré-processamento

O tratamento e a padronização dos atributos seguiram as seguintes etapas estruturadas:

- 1 **Limpeza e Filtragem:** Descarte de identificadores (IDs) irrelevantes e exclusão de duplicatas nominais.
- 2 **Engenharia de Atributos:** Extração de valores numéricos de campos textuais e cálculo da idade dos veículos na base *Used Car Price*.
- 3 **Tratamento de Dados Ausentes:** Imputação pela mediana ou moda para perdas intermediárias ( $\leq 50\%$ ) e eliminação de registros severos.
- 4 **Codificação Categórica:** Aplicação de *One-Hot Encoding* ( $\leq 100$  categorias) e *Label Encoding* para alta cardinalidade.
- 5 **Normalização:** Redimensionamento para o intervalo  $[0, 1]$  via *Min-Max Scaler*.

# Modelos Conexionistas e Neuro-Fuzzy

Foram avaliados e contrapostos quatro algoritmos divididos em dois paradigmas principais:

## Redes Neurais Artificiais:

- **MLP:** Ajuste global por hiperplanos e retropropagação de erro.
- **RBF Network:** Aproximação puramente local baseada em centros de influência.

## Sistemas Neuro-Fuzzy:

- **ANFIS:** Estrutura híbrida Takagi-Sugeno associada a partições em grade.
- **FNN-FCM:** Redução de regras difusas por meio de agrupamento multidimensional do espaço.



## Definição dos Parâmetros Investigados

A exploração sistemática do espaço de busca envolveu os seguintes hiperparâmetros por modelo:

- **MLP:** Número de camadas ocultas, densidade de neurônios, funções de ativação (*ReLU*, *tanh*, *logistic*) e termo de regularização L2 ( $\alpha$ ).
- **RBF:** Quantidade de centros da camada oculta, raio de espalhamento ( $\sigma$ ) e parâmetro de regularização Ridge.
- **ANFIS:** Número e geometria das funções de pertinência (triangular, gaussiana, sino), taxa de aprendizado e regularização consequente ( $\lambda$ ).
- **FNN-FCM:** Número de clusters difusos, expoente de fuzificação (*fuzziness*) e limiares de similaridade para poda de regras.

# Protocolo Experimental

A metodologia foi desenhada para garantir a robustez e a reprodutibilidade dos resultados:

- **Divisão dos Dados:** Particionamento estrito de 64% para treinamento, 16% para validação e 20% isolados exclusivamente para o teste final.
- **Otimização Sistemática:** Utilização da biblioteca *Optuna* com 15 tentativas (*trials*) guiadas por validação cruzada *5-fold*.
- **Validade Estatística:** Execução de 21 rodadas independentes para cada cenário, mitigando os efeitos da inicialização estocástica dos parâmetros dos modelos.

# Engenharia de Execução Distribuída

Para viabilizar a carga computacional intensiva dos modelos Neuro-Fuzzy em bases massivas, a execução foi segmentada em quatro nós distintos:

## Distribuição de Carga

- **Computador 1:** *Flight Price* operando sob o algoritmo ANFIS.
- **Computador 2:** *Flight Price* executando exclusivamente o modelo FNN-FCM.
- **Computador 3:** *Flight Price* avaliando as RNAs puras (MLP e RBF).
- **Computador 4:** Execução integral dos quatro algoritmos para as bases *Superstore*, *Used Car Price* e *Obesity*.

## Métricas de Avaliação Utilizadas

A aferição quantitativa dos erros residuais baseou-se em cinco métricas complementares:

- **MSE e RMSE:** Avaliam a magnitude dos desvios elevando os resíduos ao quadrado, penalizando de forma mais acentuada a presença de *outliers*.
- **MAE:** Média linear das diferenças absolutas, mantendo a escala original da variável avaliada.
- **Coeficiente de Determinação ( $R^2$ ):** Indica a proporção da variância total explicada matematicamente pelo modelo.
- **MAPE:** Erro percentual médio voltado ao entendimento dos impactos relativos das estimativas.

## Resultados: Superstore (Profit)

**Tabela:** Desempenho Preditivo - Dataset Superstore (21 execuções)

| Modelo       | MSE                  | RMSE              | MAE              | $R^2$             |
|--------------|----------------------|-------------------|------------------|-------------------|
| MLP          | 7570,3 $\pm$ 3621,6  | 84,70 $\pm$ 20,39 | 27,97 $\pm$ 8,61 | 0,9117 $\pm$ 0,04 |
| RBF          | 58798,7 $\pm$ 4219,0 | 242,33 $\pm$ 8,63 | 56,52 $\pm$ 0,66 | 0,3140 $\pm$ 0,05 |
| <b>ANFIS</b> | 5283,2 $\pm$ 0,00    | 72,69 $\pm$ 0,00  | 25,38 $\pm$ 0,00 | 0,9384 $\pm$ 0,00 |
| FNN-FCM      | 51644,5 $\pm$ 441,7  | 227,25 $\pm$ 0,95 | 62,69 $\pm$ 0,23 | 0,3974 $\pm$ 0,00 |

- **Destaque:** ANFIS obteve o melhor desempenho e estabilidade absoluta (variância zero) nesta base.

## Resultados: Flight Price

**Tabela:** Desempenho Preditivo - Dataset Flight Price (21 execuções)

| Modelo  | MSE ( $\times 10^6$ ) | RMSE                | MAE                | $R^2$             |
|---------|-----------------------|---------------------|--------------------|-------------------|
| MLP     | $20,07 \pm 0,31$      | $4480,2 \pm 35,6$   | $2643,8 \pm 26,4$  | $0,9651 \pm 0,00$ |
| RBF     | $117,3 \pm 17,3$      | $10802,4 \pm 803,1$ | $8414,1 \pm 718,9$ | $0,8443 \pm 0,01$ |
| ANFIS   | $36,51 \pm 0,05$      | $6043,10 \pm 4,06$  | $3968,7 \pm 9,59$  | $0,9289 \pm 0,00$ |
| FNN-FCM | $45,82 \pm 0,00$      | $6769,2 \pm 0,21$   | $4577,2 \pm 4,81$  | $0,8816 \pm 0,01$ |

- **Destaque:** O modelo MLP demonstrou superioridade em lidar com a alta volumetria de dados desta base.

## Resultados: Used Car Price

**Tabela:** Desempenho Preditivo - Dataset Used Car Price (21 execuções)

| Modelo  | MSE ( $\times 10^8$ ) | RMSE                 | MAE                  | $R^2$             |
|---------|-----------------------|----------------------|----------------------|-------------------|
| MLP     | $9,63 \pm 2,43$       | $30851,2 \pm 3534,3$ | $15483,3 \pm 1729,5$ | $0,7202 \pm 0,03$ |
| RBF     | $10,06 \pm 0,10$      | $31727,2 \pm 169,0$  | $16034,8 \pm 161,7$  | $0,0069 \pm 0,00$ |
| ANFIS   | $11,21 \pm 0,00$      | $33487,5 \pm 0,00$   | $16576,7 \pm 0,00$   | $0,5968 \pm 0,00$ |
| FNN-FCM | $9,54 \pm 0,00$       | $30897,5 \pm 0,00$   | $15946,1 \pm 0,00$   | $0,0399 \pm 0,03$ |

- **Complexidade:** A base Used Car Price apresentou o maior desafio de mapeamento para todos os modelos.

## Resultados: Obesity (Weight)


**Tabela:** Desempenho Preditivo - Dataset Obesity (21 execuções)

| Modelo  | MSE              | RMSE             | MAE              | $R^2$              |
|---------|------------------|------------------|------------------|--------------------|
| MLP     | $96,14 \pm 3,92$ | $9,80 \pm 0,19$  | $6,48 \pm 0,15$  | $0,8637 \pm 0,01$  |
| RBF     | $114,0 \pm 2,64$ | $10,67 \pm 0,12$ | $7,40 \pm 0,09$  | $0,8381 \pm 0,00$  |
| ANFIS   | $300,9 \pm 0,00$ | $17,34 \pm 0,00$ | $13,88 \pm 0,00$ | $0,5369 \pm 0,00$  |
| FNN-FCM | $287,7 \pm 0,00$ | $16,96 \pm 0,00$ | $13,41 \pm 0,00$ | $-0,0003 \pm 0,00$ |

- **Observação:** Modelos puramente conexionistas (MLP/RBF) sobressaíram-se significativamente nesta tarefa.




# Estabilidade do Poder Preditivo: $R^2$ (Flight Price)




- O  $R^2$  indica a proporção da variância dos preços explicada de forma consistente nas 21 execuções.
- A baixíssima dispersão reafirma que o **MLP** e o **ANFIS** não dependeram de sorte para atingir seu alto desempenho.

# Estabilidade Estatística: RMSE (Flight Price)




- O **RMSE** penaliza desvios maiores e avalia a robustez frente à inicialização estocástica.
- O gráfico confirma a estabilidade determinística das abordagens híbridas e a consistência em média do **MLP**.

# Estabilidade do Erro Médio: MAE (Flight Price)




- O **MAE** mensura o erro linear médio diretamente na escala real de preço das passagens aéreas.
- A dispersão compacta evidencia que o comportamento preditivo do **MLP** e do **ANFIS** se mantém confiável entre as rodadas.

# Estabilidade do Erro Relativo: MAPE (Flight Price)




- O **MAPE** expressa o desvio em termos percentuais, facilitando a compreensão do impacto do erro.
- Fica claro que o **MLP** consegue manter uma margem de erro relativo menor e mais previsível.

# Aderência Espacial: MLP (Flight Price)



- **MLP:** Exibe alta aderência à diagonal ideal de identidade, garantindo consistência preditiva mesmo em faixas de valores elevados.

# Aderência Espacial: ANFIS (Flight Price)



- **ANFIS:** Apresenta boa concentração na região central, porém exibe uma clara tendência de subestimação em instâncias de cauda longa (*outliers*).

## Discussão Crítica: Compromissos Técnicos

### O Dilema entre Transparência e Precisão:

- O MLP sobressai-se no mapeamento geral, mas a distribuição de seus pesos sinápticos atua de forma opaca (*black-box*).
- Os Sistemas Neuro-Fuzzy extraem regras interpretáveis do tipo SE-ENTÃO, porém sacrificam a flexibilidade preditiva em distribuições amorfas.

### O Problema da Dimensionalidade:

- O particionamento em grade do ANFIS gera um crescimento exponencial de regras para bases com mais de 30 atributos, inviabilizando processamentos massivos em hardware convencional.

# Conclusões e Trabalhos Futuros

## Principais Contribuições do Estudo:

- Confirmação de que não existe um algoritmo soberano para todos os domínios, validando o mapeamento empírico da Inteligência Computacional.
- Validação prática de uma arquitetura de processamento distribuído para contornar gargalos computacionais complexos de algoritmos híbridos.

## Direcionamentos Futuros:

- Integração de métodos formais de redução de dimensionalidade (como PCA) antes da fuzificação do espaço de atributos.
- Exploração de algoritmos evolucionários para a execução automatizada de podas estruturais em bases de regras redundantes.



# Referências Bibliográficas I

- ❶ G. A. Azevedo and M. E. T. Souza, "Atividade 03 - Redes Neurais e Sistemas Neuro-Fuzzy," 2026. [Online]. Disponível em:  
<https://github.com/alvarengazv/rna-neuro-fuzzy-ic>.
- ❷ D. E. Rumelhart, G. E. Hinton, and R. J. Williams, "Learning representations by back-propagating errors," *Nature*, vol. 323, no. 6088, pp. 533–536, 1986.
- ❸ J. Moody and C. J. Darken, "Fast learning in networks of locally-tuned processing units," *Neural Computation*, vol. 1, no. 2, pp. 281–294, 1989.
- ❹ J.-S. R. Jang, "ANFIS: adaptive-network-based fuzzy inference system," *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 23, no. 3, pp. 665–685, 1993.
- ❺ C.-T. Lin and C. S. G. Lee, "Neural-network-based fuzzy logic control and decision system," *IEEE Transactions on Computers*, vol. 40, no. 12, pp. 1320–1336, 1991.
- ❻ A. M. Silva, "Inteligência Computacional: Notas de Aula 11 — Redes Neurais Artificiais," Notas de Aula, 2026.
- ❼ A. M. Silva, "Inteligência Computacional: Notas de Aula 12 — Redes Neuro-Fuzzy," Notas de Aula, 2026.

# Dúvidas?



Muito obrigado!

`guilherme@aluno.cefetmg.br`

`maria@aluno.cefetmg.br`